

基于高斯过程的火球直径拖曳拟合参数预测：可行性、增量学习与异源数据融合

数学公式使用 $...$ (行内) 与 $...$ (独立行), 请在支持 **MathJax** / **KaTeX** 的预览中查看 (如 VS Code 安装 Markdown+Math、或 Typora、或导出 HTML)。

1. 问题与数据形式

1.1 目标

- 输入：炸药当量 (kg TNT 当量)、含铝量 (%) 等少量可控/可测参数, 可记为向量 $\mathbf{x} \in \mathbb{R}^d$ (当前 $d = 2$ 或可扩展)。
- 输出：火球直径随时间曲线经拖曳函数

$$D(t) = K(1 - B e^{-Ct^2})$$

拟合得到的参数 (K, B, C) , 可记为 $\mathbf{y} \in \mathbb{R}^3$ (或对 B, C 做约束变换后的等价参数化)。

1.2 训练数据

- 真实实验：每个样本为 $(\mathbf{x}^{(i)}, K^{(i)}, B^{(i)}, C^{(i)})$, 噪声来源包括实验条件、测量、以及「先拟合曲线再反演参数」的误差传递。
- 物理仿真：同构的 $(\mathbf{x}, K, B, C)$, 但由数值模型得到；系统偏差与实验不同, 且通常更光滑、不确定性结构不同。

1.3 建模策略 (用户拟定)

在样本量很小的前提下, 用高斯过程 (**Gaussian Process, GP**) 建立

$$\mathbf{x} \mapsto (K, B, C)$$

的回归关系；新实验/新仿真到来时更新模型；仿真样本以低于真实实验的权重参与训练。

下文从可行性、增量 **GP**、加权/多保真三方面论证, 并指出主要风险与验证要点。

2. 用 GP 联系 (当量, 含铝量) 与 (K, B, C) 的可行性

2.1 合理性

- 小样本、低维输入： $d = 2$ 时, 经典 GP 的「维度灾难」压力较小；核函数可表达「相近配方 $\rightarrow$ 相近拟合参数」的平滑假设, 与物理直觉一致。
- 多输出： (K, B, C) 是三维向量。可行做法包括：
 - 独立 **GP**：对 K, B, C 各建一个 GP (实现简单, 忽略输出间相关)；
 - 多输出 **GP** / 线性模型核 (**LMC**)：显式建模 K, B, C 之间的相关, 在样本极少时若先验设得过强可能过拟合, 但理论上更一致。
- 与曲线预测的关系：若新点预测得到 $(\hat{K}, \hat{B}, \hat{C})$, 则直径曲线由解析式给出, 无需再对整条 $D(t)$ 做 GP, 计算与可解释性较好。

2.2 局限与需注意点

- 参数化非唯一性 / 约束: B, C 往往有物理或数值可行域 (如 $B \in (0, 1]$ 、 $C > 0$)。建议在变换空间回归, 例如 $B = \sigma(\tilde{B})$ 、 $C = \text{softplus}(\tilde{C})$, 对 GP 在 $(\tilde{B}, \tilde{C})$ 上建模, 再映射回原空间, 避免无意义外推。
- 误差传递: (K, B, C) 来自对离散 $D(t)$ 的拟合, 其不确定性异质且相关; 理想做法是把拟合的后验或协方差带入二级模型 (见第 5 节加权思路); 小样本时至少应对残差大的点加大噪声方差。
- 外推: GP 在训练凸包之外预测方差会变大, 但均值仍可能过于自信 (取决于核与超参)。小样本下主动在边界配方补点或采用保守外推 (t 过程、增大噪声先验) 更稳妥。

结论: 在低维输入 + 显式参数约束/变换的前提下, 用 GP 学习 $\mathbf{x} \rightarrow (K, B, C)$ 在工程上是可行且常见的; 主要风险在外推与忽略拟合误差结构, 需用验证与不确定性展示来约束使用范围。

3. 小样本下选择 GP 的合理性 (简要)

方面	说明
数据需求	相比深度网络, GP 在 n 很小时更不易「空转」, 且天然给出预测方差。
归纳偏置	核长度尺度可编码「当量/含铝量变化多快会影响 K, B, C 」; 可通过多核或 ARD 自动尺度。
可更新性	存在从精确到近似的多种序贯更新路径 (下一节), 适合「陆续做实验」的场景。

深度 GP、神经网络等可作为样本增多后的升级路线, 但不否定当前阶段 GP 作为基线与不确定性量化工具的价值。

4. 新数据到来时: 可迭代 / 序贯的高斯过程回归方法

「迭代」在文献中常对应: 在线学习、序贯更新、稀疏化近似, 而非重新从零训练不可行。

4.1 精确 GP 的秩一更新 (数据量仍小时)

若采用共轭指数噪声模型 (回归中常见为高斯似然), 新样本 $(\mathbf{x}_{\text{new}}, \mathbf{y}_{\text{new}})$ 加入后, 对固定超参数而言, 可用 **Sherman-Morrison-Woodbury** 或 Cholesky 秩一更新更新 $(K + \sigma^2 I)^{-1}$ 或分解, 复杂度约 $O(n^2)$ 每次新点。

- 优点: 数学上等价于全量重算, 适合 n 仍较小 (如几十以内)。
- 缺点: n 增大后 $O(n^3)$ 训练、 $O(n^2)$ 存储成为瓶颈。

4.2 超参数的「迭代」: 经验贝叶斯 / 边际似然优化

每批新数据到达后, 可重新优化边际似然 (或对超参做 MCMC)。这不是「闭式递推」, 但是标准实践:

- 新数据少时: 可在旧超参附近 **warm-start** 微调, 减少不稳定。
- 若坚持严格在线且避免重复优化: 可考虑稀疏变分 GP (SVGP) 等, 用小批梯度更新变分参数与部分超参 (见下)。

4.3 稀疏与伪输入: FITC / VFE / SVGP

当 n 增长, 用 $m \ll n$ 个诱导点 (inducing points) 近似完整 GP:

- **FITC / PITC**: 早期稀疏近似, 实现相对直接。
- **VFE** (变分自由能)、**SVGP**: 变分推断, 支持小批量 (mini-batch) 与随机梯度, 适合「流式」追加数据、反复更新。

含义: 用户所说的「产生新数据就更新 GP」在工程上常落地为: **SVGP** + 周期性或每批新实验后的变分/超参更新, 而非永远保留全部历史点的精确核矩阵。

4.4 其他相关方向 (可选)

- 递归 **GP** / 状态空间近似: 一维输入时间序列上常见; 对二维配方空间不总是首选。
- **Student-t** 过程: 更厚尾, 对异常点更稳健, 更新公式比 GP 复杂, 可作为稳健化扩展。

结论: 小 n : 精确 GP + Cholesky 重算或秩一更新即可; n 增大或流式: 诱导点 + 变分 (**SVGP**) 是主流可迭代方案; 超参建议随数据批次再优化或微调, 并 warm-start。

5. 真实实验与物理仿真: 降低仿真权重的常用方法

目标: 同一 GP (或多输出 GP) 同时吃高可信度实验与低可信度仿真, 但仿真不应支配边界与全局形状。

5.1 异方差高斯噪声 (最直接)

对每个样本 i 设观测噪声方差 σ_i^2 (或对仿真统一 $\sigma_{\text{sim}}^2 \gg \sigma_{\text{exp}}^2$)。

- 实现: 加权最小二乘视角等价于对仿真点赋予更大噪声 $\rightarrow$ 核回归中该点对后验的「拉力」变弱。
- 注意: σ_i 需可解释 (例如由仿真网格收敛性、或与实验对比的残差标定), 避免纯手调无界。

5.2 仿真作为「有偏」观测: 常数偏移或残差建模 (多保真简化版)

- 残差学习: 令 $y = y_{\text{exp}}$ 为真值, 仿真给出 $y_{\text{sim}}(\mathbf{x})$; 建模

$$y_{\text{exp}}(\mathbf{x}) = f(\mathbf{x}) + \epsilon, \quad y_{\text{sim}}(\mathbf{x}) = f(\mathbf{x}) + \delta(\mathbf{x}) + \epsilon'$$

其中 f 为共享的「物理一致」部分, δ 为仿真偏差 (可用另一小 GP 或简单参数)。

- 效果: 实验点主要约束 f , 仿真在不与实验冲突处填充形状, 权重通过 ϵ, ϵ' 与 δ 的先验调节。

5.3 线性模型共区域化 (LMC) 与多保真核

将「数据源」(实验/仿真) 视为第二个输入维或多输出通道, 用 **coregionalization** 建模通道间相关; 再通过噪声结构或核幅度使实验通道更窄。适合理论完备但标定需要更多数据或专家假设。

5.4 样本复制与加权（需谨慎）

简单地对仿真点重复复制以「伪增权」在概率上不等价于正确噪声模型，易导致校准错误的置信区间；更推荐显式 σ_i^2 或多保真构造。

结论：优先推荐：对 K, B, C 各任务（或联合输出）使用 输入相关或分组相关的噪声方差（实验小、仿真大）；有精力时再上 残差/多保真 **GP** 分离系统偏差。

6. 验证、风险与使用建议

1. 交叉验证：Leave-one-out 或重复 K-fold（样本极少时以 LOO-CV + 可视化预测区间为主）。
2. 物理约束：预测 $(\hat{K}, \hat{B}, \hat{C})$ 后检查 $D(t)$ 单调性、渐近值与实验量级是否合理。
3. 外推告警：当（当量, 含铝）落在训练点凸包外时，应放大报告不确定性或拒绝自动推荐。
4. 仿真标定：若有部分配方同时存在实验与仿真，可用其差异估计 δ 或 σ_{sim} ，使权重有数据支撑而非纯主观。
5. 版本化：每次更新 GP（超参或诱导点）后保存数据版本、核与超参、代码 **commit**，便于复现实验与回溯。

7. 总结

议题	结论
GP 预测 (K, B, C)	可行；建议在变换域建模并处理约束；注意拟合误差与外推。
小样本	GP 合理，优于盲目上大模型；可先独立三输出 GP 再考虑多输出核。
迭代更新	小 n : 精确 GP + 重算/秩一更新；大 n 或流式：诱导点 + SVGP 小批更新；超参建议批次微调。
仿真降权	推荐异方差噪声（仿真大方差）；进阶用残差/多保真或 coregionalization。

该路线与「样本少、陆续积累、实验贵、仿真廉」的设定一致；可行性高，合理性取决于噪声建模、参数化约束与验证流程是否到位。后续若样本增至数百上千，可再评估稀疏 GP 的诱导点数目或切换到深度核/神经网络并保留 GP 层作为不确定性模块。

参考文献方向（便于检索，非完整引用）

- Rasmussen & Williams, *Gaussian Processes for Machine Learning* (GP 基础与回归)。

- Quinonero-Candela & Rasmussen, *A Unifying View of Sparse Approximate Gaussian Process Regression* (FITC/VFE 等)。
- Hensman et al., *Gaussian Processes for Big Data* (SVGP / 随机变分)。
- Kennedy & O'Hagan, *Bayesian calibration of computer models* (多保真、偏差建模思想)。

(具体卷期页码请按贵方写作规范在定稿时补全。)